

Laboratorio 2: Biblical Text Mining

Carlos Bugueño, Constantino Bekios y Vicente Moyano

29 de junio de 2026

Resumen

En este laboratorio se desarrolló un sistema completo de análisis del texto bíblico utilizando técnicas clásicas de procesamiento de lenguaje natural (NLP). Se implementaron modelos de representación como TF-IDF, métodos de similitud, clasificación de texto, modelos n-gram y análisis de sentimiento.

Además, se evaluó el sistema con distintos tamaños de dataset, lo que permitió analizar cómo el volumen de datos impacta directamente en el desempeño de los modelos.

1. Introducción

La Biblia constituye un corpus textual de gran tamaño formado por múltiples libros con distintos estilos literarios. Esta diversidad la convierte en un dataset adecuado para aplicar técnicas de procesamiento de lenguaje natural.

El objetivo del laboratorio es analizar este corpus mediante herramientas de NLP, resolviendo tareas como búsqueda semántica, clasificación automática y generación de texto.

2. Metodología

2.1. Preprocesamiento

Se aplicaron las siguientes técnicas:

- Conversión del texto a minúsculas
- Eliminación de caracteres especiales
- Eliminación de signos de puntuación
- Tokenización
- Eliminación de stopwords

2.2. Representación TF-IDF

Se utilizó TF-IDF para representar cada versículo como un vector numérico, permitiendo calcular similitud entre documentos.

2.3. Modelos implementados

- Clasificador Naive Bayes
- Búsqueda semántica con similitud del coseno
- Modelos n-gram (bigrama, trigram y cuatrigrama)
- Análisis de sentimiento con TextBlob

3. Resultados

Se evaluó el sistema en tres escenarios:

- Dataset pequeño (2000 versículos): accuracy $\approx 0,84$
- Dataset mediano (10000 versículos): accuracy $\approx 0,30$
- Dataset completo (31102 versículos): accuracy $\approx 0,38$

Se observa que el clasificador presenta buen desempeño en datasets pequeños, pero su precisión disminuye al aumentar la complejidad y la cantidad de clases.

El sistema de búsqueda mostró resultados coherentes en todos los casos, mientras que los modelos n-gram mejoraron la coherencia al aumentar el contexto.

3.1. Interpretación del sistema de búsqueda

Se utilizó la consulta:

“Dios creó la tierra”

Los resultados obtenidos muestran que el sistema recupera versículos relacionados temáticamente, aunque no coincidan exactamente las mismas palabras.

El resultado más relevante corresponde a un versículo de Jeremías con múltiples ocurrencias del término “tierra”, lo que indica que TF-IDF asigna un alto peso a palabras clave presentes en la consulta.

Otros resultados incluyen versículos de Mateo, Levítico, Salmos y Génesis. Este último es especialmente coherente con la consulta, ya que hace referencia directa a la creación, lo que valida el comportamiento del sistema.

Esto demuestra que el modelo es capaz de identificar similitudes basadas en términos relevantes, aunque no logra una comprensión semántica profunda del lenguaje.

4. Análisis crítico

Uno de los principales hallazgos es que el tamaño del dataset afecta significativamente el rendimiento del modelo. En datasets pequeños, la clasificación es más sencilla, lo que resulta en alta precisión. Sin embargo, al aumentar el número de clases y la similitud entre textos, el problema se vuelve más complejo.

Esto sugiere que el problema de clasificación en este contexto presenta alta superposición entre clases, lo que dificulta su separación utilizando modelos lineales simples.

El modelo TF-IDF es eficaz para representar documentos y calcular similitud, pero no captura el significado semántico profundo.

Los modelos n-gram muestran que el aumento del contexto mejora la coherencia local del texto generado. Sin embargo, no logran capturar la estructura global del lenguaje.

5. Análisis de visualizaciones

Las siguientes visualizaciones fueron generadas utilizando el dataset completo (31102 versículos), lo que permite observar patrones globales representativos de todo el corpus.

5.1. Heatmap




Figura 1: Heatmap de similitud entre libros

El heatmap presenta una diagonal marcada, indicando alta similitud de cada libro consigo mismo. Además, se observan agrupaciones que reflejan similitudes entre libros del mismo testamento. Este comportamiento sugiere que existen patrones lingüísticos comunes entre ciertos libros, especialmente dentro del mismo testamento. Esto implica que el lenguaje utilizado presenta similitudes estructurales y de vocabulario, lo que puede dificultar la clasificación al generar ambigüedad entre clases similares.

5.2. Distribución de longitud




Figura 2: Distribución de longitud de versículos

Se observa una distribución aproximadamente normal, concentrada entre 8 y 20 palabras, lo que indica una estructura homogénea del corpus. Esta característica implica que la longitud de los versículos no constituye una variable discriminante significativa para tareas de clasificación, ya que no presenta suficiente variabilidad entre distintas clases.

5.3. PCA




Figura 3: Proyección PCA

El PCA muestra una alta dispersión sin clusters definidos, lo que evidencia la dificultad de separar claramente los textos. La ausencia de clusters claramente definidos indica que los datos presentan una alta superposición en el espacio de características, lo que confirma la dificultad del modelo para separar las distintas clases. Este comportamiento es consistente con la disminución del accuracy observada en datasets de mayor tamaño.

5.4. Sentimiento




Figura 4: Sentimiento promedio por libro

Los valores cercanos a cero indican neutralidad en el lenguaje, con leves variaciones entre libros. Esto sugiere que el análisis de sentimiento aporta baja capacidad discriminativa en este contexto para diferenciar entre libros en este contexto, debido a la naturaleza homogénea del lenguaje del corpus.

6. Conclusiones

El desarrollo de este laboratorio permitió implementar un sistema completo de análisis de texto basado en técnicas clásicas de procesamiento de lenguaje natural.

Uno de los principales resultados obtenidos es que el desempeño de los modelos depende fuertemente del tamaño y la complejidad del dataset. Mientras que en escenarios simples el clasificador presenta alta precisión, en contextos más complejos y con mayor cantidad de clases su rendimiento disminuye significativamente.

El uso de TF-IDF permitió construir representaciones efectivas para tareas de similitud y búsqueda semántica, demostrando ser una herramienta adecuada para la recuperación de información. Sin embargo, sus limitaciones se hacen evidentes al no capturar relaciones semánticas profundas.

Por otra parte, los modelos n-gram evidenciaron que el aumento del contexto mejora la coherencia local del texto generado, aunque no logran modelar la estructura global del lenguaje.

El análisis de visualizaciones permitió comprender mejor la estructura del corpus, evidenciando una alta superposición entre clases, lo que dificulta la tarea de clasificación utilizando modelos simples.

En este sentido, los resultados sugieren que problemas de mayor complejidad requieren técnicas más avanzadas, como modelos basados en aprendizaje profundo o representaciones semánticas más sofisticadas.

Finalmente, este trabajo no solo permitió implementar distintas técnicas, sino también comprender sus limitaciones en escenarios reales, destacando la importancia del análisis crítico en el desarrollo de sistemas de procesamiento del lenguaje natural.